

# Data Cleaning & Data Analytics

*Überblick über die wesentlichen Lern- und Lehrinhalte aus den praktischen Einheiten*

## Leitidee

Data Cleaning ist kein vorgelagerter technischer Schritt, der einmal erledigt wird. Jede Bereinigung, jede Umkodierung, jede Imputation und jede Modellentscheidung ist eine fachliche Annahme. Gute Analyse bedeutet daher: Entscheidungen begründen, Wirkungen prüfen und Ergebnisse vorsichtig interpretieren.

## 1. Datenanalyse als Entscheidungsprozess

In den praktischen Einheiten wurde Datenanalyse nicht als lineare Abfolge von Befehlen behandelt, sondern als wiederholter Zyklus aus Verstehen, Prüfen, Bereinigen, Modellieren und Interpretieren. Die zentrale Frage lautet nicht: "Welche Funktion muss ich ausführen?", sondern: "Welche Annahme treffe ich gerade über die Daten?"

- **Rohdaten sind selten neutral.** Sie enthalten Messfehler, Sondercodes, fehlende Werte, Eingabefehler, extreme Werte und Spuren des Erhebungsprozesses.
- **Technische Bereinigung verändert die Datenbasis.** Dadurch können Zusammenhänge stärker, schwächer oder überhaupt erst sichtbar werden.
- **Grenzwerte sind selten rein objektiv.** Sie müssen zur Fragestellung, zum Datensatz und zum Fachwissen passen.
- **Ein Modell beschreibt eine bestimmte Sicht auf die Daten.** Es ist keine direkte Abbildung der Wirklichkeit und schon gar kein automatischer Kausalbeweis.

Jede Datenbereinigung ist zugleich eine Interpretation. Deshalb sollte man nicht nur das Ergebnis dokumentieren, sondern auch den Grund der Entscheidung und ihre mögliche Wirkung.

## 2. Daten verstehen: von Rohzeichen zu nutzbarer Analyse

Daten sind nicht automatisch Information. Eine Zahl, ein Datum, ein Textfragment oder ein Code wird erst durch Kontext analytisch brauchbar. Vor jeder Bereinigung muss daher geklärt werden, was ein Wert repräsentiert: Messwert, Kategorie, ID, Sondercode, Fehlwert, Preis, Menge oder Zeitangabe. Formal saubere Daten können fachlich falsch sein, wenn Bedeutung, Einheit oder Entstehung nicht verstanden wurden.

### Vor der Bereinigung: Bedeutung klären

Die Datenart bestimmt die sinnvolle Bereinigung. Metrische Daten brauchen Einheiten, plausible Wertebereiche und Ausreißerdiagnostik. Kategorische Daten brauchen konsistente Labels und Referenzlisten. Textdaten brauchen Entscheidungen über Metadaten, Normalisierung, Mehrsprachigkeit und semantisch wichtige Zeichen. Metadaten wie Zeitstempel, Quelle, Plattform, Sprache oder Version sind dabei nicht bloß Zusatzinformation, sondern oft der Schlüssel zur richtigen Interpretation.

- Was beschreibt der Wert wirklich, und in welcher Einheit liegt er vor?
- Welche Codes bedeuten fehlend, ungültig, nicht zutreffend oder absichtlich leer?
- Welche Informationen würden durch eine scheinbar harmlose Vereinheitlichung verloren gehen?

### Dirty Data als reales Analyseproblem

Dirty Data entsteht im gesamten Datenlebenszyklus: bei Eingabe, Erfassung, Migration, Integration, Systemwechseln, veralteten Daten, fehlenden Standards oder unklarer Verantwortung. Die Beispiele Raumfahrt, COVID-Dashboards und NLP zeigen denselben Mechanismus: Einheitenmix, Meldeverzug, Nachmeldungen, Encoding-Fehler oder zu aggressive Textbereinigung können falsche Trends, falsche Modelle und falsche Entscheidungen erzeugen. Ziel ist daher nicht, Daten nur sauber aussehen zu lassen, sondern ihre Aussagekraft zu verbessern.

## Qualität und Ethik als Kontrollfragen

Die 5 C's der Datenqualität sind als Prüffragen nützlich: Sind die Daten **clean**, **consistent**, **conformed**, **current** und **complete**? Diese Fragen ersetzen keine Fachprüfung, verhindern aber blinde Routine. Ebenso wichtig ist die ethische Dimension: Konsent, Klarheit, Fairness, Kontrolle, Transparenz und mögliche Schäden. Nur weil Daten technisch verfügbar sind, folgt daraus nicht automatisch, dass ihre Nutzung sinnvoll, fair oder verantwortbar ist.

## 3. Sprache als Datenobjekt

Textdaten wirken auf den ersten Blick leicht zugänglich, sind analytisch aber komplex. Ein Text besteht neben Wörtern auch aus Satzzeichen, Emojis, Hashtags, URLs, Tippfehlern, Metadaten, Paratexten und Spuren des Mediums. Gerade in Social-Media-Posts, Chats, Supporttickets oder Reklamationen ist Sprache oft situativ, verkürzt, emotional, fehlerhaft und dialogisch. Solche Texte sind zwar schriftlich, ähneln aber häufig gesprochener Sprache.

Für die Analyse ist daher wichtig, **zwischen abstraktem Sprachsystem und konkreter Sprachverwendung zu unterscheiden**. Regeln, die bei redigierten Berichten funktionieren, passen nicht automatisch für Kundenfeedback, Microblogging oder Chatkommunikation. Textbereinigung bedeutet deshalb Unregelmäßigkeiten zu entfernen und dabei jene Bedeutungsebenen zu erhalten, die für die Fragestellung relevant sind.

Auch digitale Zeichen sind mehr als bloße Strings. Schriftzeichen, Wortbestandteile, Emojis, Icons, Links oder Satzzeichen können Bedeutung tragen. Begriffe wie Graph, Graphem, Morph oder Morphem machen deutlich, dass sichtbare Zeichenform und sprachliche Bedeutung nicht identisch sind. Praktisch wird das etwa bei OCR-Fehlern, Unicode-Normalisierung, diakritischen Zeichen, Mojibake, Dialekt, Namensabgleich, Lemmatisierung oder Decompounding relevant.

Semiotische Modelle wie jene von Saussure und Peirce erinnern daran, dass Bedeutung nicht allein im Zeichen selbst liegt, sondern aus Ausdruck, Kontext und Interpretation entsteht. Für NLP heißt das: Ein Token kann Wort, Symbol, Emoji, Satzzeichen, Link oder Icon sein. Pauschales Entfernen solcher Elemente kann Texte ordentlicher machen, aber die Analyse weniger valide.

### Korpus, Dokument, Satz und Wort

Ein Korpus ist keine neutrale Sammlung, sondern das Ergebnis konkreter Auswahlentscheidungen. Quellen, Zeitraum, Plattform, Sprache, Ausschlussregeln und Metadaten bestimmen, welche Aussagen später möglich sind. Auch die Zerlegung in Dokumente, Sätze und Tokens ist eine analytische Entscheidung. In spontaner Kommunikation sind Satzgrenzen, Ellipsen, Mehrfachzeichen oder Emojis oft wichtiger als eine formal perfekte Segmentierung.

Bei deutschen Texten sind Flexion und Komposita besonders zu beachten. Wortformen wie „läuft“, „lief“ und „gelaufen“ können zusammengehören; Komposita wie „Bluetooth-Verbindungsabbruchsproblem“ bündeln mehrere Themen in einem Wort. Lemmatisierung, Stemming oder Decompounding können Analysen verbessern, aber auch Bedeutung verzerren. Bindestriche, Produktnamen, IDs und Fachbegriffe dürfen daher nicht blind gesplittet werden.

## 4. Text-Preprocessing: vom Rohtext zur Analysebasis

Preprocessing ist keine universelle Pipeline, sondern eine Folge begründeter Entscheidungen. Der passende Ablauf hängt vom Analyseziel ab: Topic-Modeling, Sentimentanalyse, Suche, Klassifikation oder Named-Entity-Erkennung benötigen unterschiedliche Formen der Bereinigung. Die zentrale Frage lautet immer:

### Welche Information ist Signal, welche ist Rauschen, und für welche Aufgabe?

Emojis, Zahlen, Hashtags oder Metadaten können je nach Fragestellung Störung oder Kerninformation sein. Für Topic-Modeling können Bestellnummern unerwünschte Artefakte erzeugen; für Prozessanalyse können sie entscheidend sein. Für Sentimentanalysen sind Negationen, Satzzeichen und Emojis oft bedeutsam; für manche Such- oder Klassifikationsaufgaben können sie dagegen reduziert werden.

### Tokenisierung, Normalisierung und Reduktion

Tokenisierung zerlegt Text in analysierbare Einheiten: Sätze, Wörter, Subwörter, Zeichen oder Satzzeichen. Dabei unterscheidet man zwischen **Types**, also eindeutigen Formen, und **Tokens**, also konkreten Vorkommen im Text.

Normalisierung vereinheitlicht Zeichenvarianten, Groß- und Kleinschreibung, Leerzeichen oder Encoding-Probleme. Reduktionsverfahren wie Stemming und Lemmatisierung fassen Wortformen zusammen: Stemming

reduziert grob auf Wortstämme, kann aber Bedeutung verfälschen; Lemmatisierung ist sprachlich genauer, setzt aber bessere Modelle voraus. Jede Reduktion erleichtert die Verarbeitung, kostet aber Information.

### Praktische Anwendung

Ein robuster Ablauf beginnt mit der manuellen Sichtung einzelner Rohtexte. Danach werden Metadaten getrennt, aber nicht vorschnell verworfen. Zeichenvarianten, Groß-/Kleinschreibung und Leerzeichen werden nachvollziehbar normalisiert. Anschließend werden Tokens erzeugt und anhand konkreter Beispiele geprüft.

Stopplisten, Negationen, Zahlen, kurze Tokens, Emojis und Sonderzeichen sollten nur mit begründetem Ziel entfernt oder behalten werden. **Libraries nehmen Arbeit ab, treffen aber implizite Annahmen** über Sprache, Tokens und Stopwörter. **Deshalb reicht es nicht, dass der Code „läuft“.**

Der wichtigste Qualitätstest ist der Vorher-Nachher-Vergleich an realen Beispielen. Nach dem Preprocessing müssen die Ergebnisse weiterhin interpretierbar sein: Topics dürfen nicht aus Encoding-Fehlern, Funktionswörtern oder Artefakten bestehen; Klassifikationen dürfen nicht durch entfernte Negationen, Emojis oder Metadaten systematisch verzerrt werden. **Entscheidend ist nicht maximale Bereinigung, sondern eine zur Fragestellung passende Analysebasis.**

## 5. Textdaten und Regular Expressions

Regular Expressions wurden in der LV als Werkzeug zur strukturierten Textbereinigung eingesetzt, etwa bei Social-Media-Posts, Weblogs und betrügerischen E-Mails. Die erste Überlegung sollte immer sein: Welche sprachlichen oder technischen Muster sind im Text tatsächlich gemeint/wichtig?

### RegEx sucht Muster, nicht Bedeutung

Eine Regular Expression erkennt formale Muster: Zeichenfolgen, Ziffernblöcke, Zeilenanfänge, etc. Sie versteht aber nicht, ob ein Treffer inhaltlich sinnvoll ist. Deshalb können zwei Fehler auftreten: Das Muster ist zu eng und übersieht relevante Fälle (*recall* zu niedrig); oder es ist zu breit und löscht bzw. extrahiert zu viel (*precision* zu niedrig). Anhand der Beispiele aus der LV:

- Bei **Social-Media-Texten** müssen Metadaten, Textinhalt, Erwähnungen, Hashtags, Tippfehler etc. oft getrennt behandelt werden.
- Bei **Weblogs** ist die Struktur meist regelmäßiger, aber ebenfalls nicht garantiert. Ein Pattern sollte daher auch mit abweichenden Zeilen umgehen können.
- Bei **Geldbeträgen** in Spam-Mails werden Zahlenformate schnell mehrdeutig: Punkt, Komma, Leerzeichen, Währungssymbol und Zusätze wie "M" können Unterschiedliches bedeuten.

### Praktische Risiken

| Risiko            | Bedeutung für die Praxis                                                                          | Gegenmaßnahme                                                                 |
|-------------------|---------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------|
| Overmatching      | Das Pattern erfasst mehr Text als gewollt und entfernt nützliche Information.                     | Mit kleinen Beispielen testen, Treffer sichtbar machen, nicht sofort löschen. |
| Undermatching     | Nur die idealtypischen Fälle werden erkannt; reale Schreibweisen bleiben übrig.                   | Varianten sammeln, Sonderfälle prüfen, iterativ erweitern.                    |
| Encoding-Probleme | Umlaute, HTML-Entitäten oder Mojibake erzeugen scheinbar neue Wörter.                             | Zeichenkodierung prüfen, Ersetzungen gezielt und nachvollziehbar durchführen. |
| Scheinpräzision   | Ein sauberer regulärer Ausdruck wirkt zuverlässig, obwohl er fachlich falsche Treffer produziert. | Nach jeder Regel Beispiele vor und nach der Bereinigung kontrollieren.        |

**Reflexionsfrage:** Welche Information soll nach der Textbereinigung erhalten bleiben, und welche darf wirklich verloren gehen?

## 6. Plausibilitätsprüfung, Ausreißer und Feature Engineering

Bei numerischen Daten beginnt die Analyse mit einem Überblick: Dimensionen, Datentypen, fehlende Werte, deskriptive Statistiken, Histogramme, Korrelationen und einfache Streudiagramme. Diese Schritte sind keine Formalität. Sie zeigen, ob Wertebereiche plausibel sind und ob die Daten zur Fragestellung passen.

## Auffällige Werte sind nicht automatisch Fehler

Am Taxi-Beispiel wurden typische Probleme realer Daten sichtbar: negative oder extrem kleine Kosten, unrealistische Entfernungen, hohe Mautbeträge, Fahrtende vor Fahrtbeginn, sehr kurze oder extrem lange Fahrten und rechnerisch unmögliche Durchschnittsgeschwindigkeiten. Solche Beobachtungen können Fehler sein, aber auch Sonderfälle. Man darf sie daher nicht mechanisch entfernen.

- Ein Ausreißer im Histogramm kann ein Datenfehler, ein Sonderfall oder ein wichtiger Hinweis sein.
- Filtergrenzen wie maximale Fahrtzeit oder plausible Geschwindigkeit müssen begründet werden.
- Nach jeder Filterung sollte geprüft werden, wie viele Daten entfernt wurden und ob bestimmte Gruppen stärker betroffen sind.
- Wenn nur ein kleiner Anteil entfernt wird, kann die Wirkung trotzdem groß sein, wenn gerade einflussreiche Beobachtungen betroffen sind.

## Feature Engineering als Diagnoseinstrument

Abgeleitete Variablen können die Daten verständlicher machen. Eine Fahrtdauer aus Start- und Endzeit, eine Durchschnittsgeschwindigkeit aus Distanz und Dauer oder ein Trinkgeldanteil aus Trinkgeld und Gesamtkosten decken Unplausibilitäten oft besser auf als die ursprünglichen Spalten. Gleichzeitig erzeugt Feature Engineering neue Annahmen: Welche Formel ist sinnvoll? Welche Einheit wird verwendet? Welche Fälle sind mathematisch nicht definiert?

**Log-Transformation:** Schiefe Verteilungen, etwa bei Firmengröße, Firmalter oder Fahrtdauer, können durch eine Log-Transformation besser modellierbar werden (mit bspw. Regressionsmodellen). Das löst aber nicht automatisch inhaltliche Probleme. Es verändert „nur“ die Skala und damit die Interpretation.

## 7. Fragebögen: vom Item zum Konstrukt

Ein Fragebogen ist kein neutraler Datengenerator. Er übersetzt theoretische Konzepte in konkrete Fragen und Antworten. Diese Übersetzung ist fehleranfällig und muss sowohl inhaltlich als auch statistisch geprüft werden.

### Items, Skalen und Konstrukte

| Begriff            | Kernidee                                                       | Beispielhafte Bedeutung                           |
|--------------------|----------------------------------------------------------------|---------------------------------------------------|
| Manifestes Merkmal | Direkt beobachtbar oder direkt messbar.                        | Alter, Wohnort, Unternehmensgröße.                |
| Latentes Konstrukt | Nicht direkt beobachtbar; wird über mehrere Items erschlossen. | Zufriedenheit, Vertrauen, Innovationsfähigkeit.   |
| Item               | Einzelne Frage oder Aussage im Fragebogen.                     | "Die Nutzung ist leicht verständlich."            |
| Skala              | Zusammenfassung mehrerer Items zu einem Messwert.              | Mittelwert oder Summenwert mehrerer Likert-Items. |

Bei latenten Konstrukten ist ein einzelnes Item meist zu schwach. Mehrere Items sollen unterschiedliche Facetten desselben Konstrukts erfassen. Diese Items dürfen aber nicht beliebig kombiniert werden; sie müssen theoretisch zusammengehören und empirisch ausreichend kohärent sein.

### Gütekriterien und Antwortverzerrungen

| Kriterium    | Frage dahinter                                                                               |
|--------------|----------------------------------------------------------------------------------------------|
| Objektivität | Würde die Erhebung, Auswertung und Interpretation unabhängig von der Person gleich ablaufen? |
| Reliabilität | Misst das Instrument zuverlässig und mit möglichst wenig Messfehler?                         |
| Validität    | Misst das Instrument wirklich das, was es messen soll?                                       |

Typische Fehlerquellen sind soziale Erwünschtheit, Zustimmungstendenzen, Tendenz zur Mitte, extreme Antwortstile und systematisches Überspringen von Items. Eine klare Formulierung, ein passendes Antwortformat, Anonymität, Pretests und Pilotstudien reduzieren diese Risiken, beseitigen sie aber nicht vollständig.

**Reliabel vs. valide:** Eine Skala kann reliabel sein, ohne valide zu sein. Konsistente Antworten bedeuten nur, dass Items zusammenhängen. Sie beweisen nicht, dass das *richtige* Konstrukt gemessen wurde.

## 8. Codierung, Missing Values und Imputation

Fehlende Werte entstehen nicht erst, wenn in der Tabelle NaN steht. Häufig sind fehlende oder ungültige Antworten mit Sonderwerten codiert, etwa negative Zahlen, Werte außerhalb der Likert-Skala etc. Der erste analytische Schritt besteht daher darin, die Bedeutung solcher Codes zu klären und sie korrekt als fehlend oder ungültig zu behandeln.

### Fehlende Werte verstehen

| Typ  | Kurzbeschreibung                                                                  | Praktische Konsequenz                                                              |
|------|-----------------------------------------------------------------------------------|------------------------------------------------------------------------------------|
| MCAR | Fehlen ist vollständig zufällig.                                                  | Löschen ist eher vertretbar, aber trotzdem Datenverlust.                           |
| MAR  | Fehlen hängt mit beobachteten Variablen zusammen.                                 | Imputation kann sinnvoll sein, wenn relevante erklärende Variablen vorhanden sind. |
| MNAR | Fehlen hängt mit dem fehlenden Wert selbst oder unbeobachteten Ursachen zusammen. | Statistisch schwer zu lösen; Domänenwissen und Sensitivitätsanalysen sind zentral. |

Zusätzlich ist wichtig, ob ganze Beobachtungen fehlen (*unit non-response*) oder nur einzelne Variablen (*item non-response*), und ob das Fehlen intendiert war, etwa durch Filterführung, oder unbeabsichtigt, etwa durch Fehler, Abbruch oder Verweigerung.

### Imputation ist kein Reparaturzauber

Imputation ersetzt fehlende Werte durch plausible Schätzungen. Dadurch bleiben mehr Fälle im Datensatz, aber es entstehen auch Risiken: Varianz kann unterschätzt werden, Zusammenhänge können verzerrt werden, und komplexe Verfahren können Muster erzeugen, die in den echten Daten so nicht existieren.

| Methode                               | Stärke                                                      | Risiko                                                                                             |
|---------------------------------------|-------------------------------------------------------------|----------------------------------------------------------------------------------------------------|
| Mittelwert / Median                   | Einfach, transparent, schnell.                              | Reduziert Varianz; kann Zusammenhänge abschwächen. Bei z-Skalierung entspricht Mittelwert meist 0. |
| Gruppenbasierte Imputation            | Berücksichtigt sinnvolle Gruppen, etwa Cluster oder Länder. | Kann Gruppenunterschiede künstlich stabilisieren oder überzeichnen.                                |
| KNN-Imputation                        | Nutzt ähnliche Fälle statt globaler Durchschnittswerte.     | Hängt stark von Distanzmaß, Skalierung und Variablenauswahl ab.                                    |
| Iterative / modellbasierte Imputation | Nutzen multivariate Zusammenhänge.                          | Mehr Annahmen, Gefahr von Overfitting und schwererer Nachvollziehbarkeit.                          |

**Modellvergleich nach Imputation:** Ein niedrigeres oder höheres  $R^2$  nach Imputation bedeutet nicht automatisch, dass das Modell besser oder schlechter ist. Häufig werden unterschiedliche Stichproben verglichen: vollständige Fälle können homogener sein als die zusätzlich einbezogenen unvollständigen Fälle.

## 9. Skalenbildung und Faktorenanalyse

Beim Fragebogendatensatz wurden aus Einzelitems Faktoren bzw. Konstrukte gebildet. Die Kernfrage lautet: Ist es vertretbar, mehrere Antworten zu einem einzigen Wert zusammenzufassen? Diese Frage muss inhaltlich und statistisch beantwortet werden.

### Vorbedingungen und Entscheidungshilfen

| Instrument         | Wofür es verwendet wird                                             | Wie es zu interpretieren ist                                                              |
|--------------------|---------------------------------------------------------------------|-------------------------------------------------------------------------------------------|
| Korrelationsmatrix | Erster Blick auf Zusammenhänge zwischen Items.                      | Zu wenig Zusammenhang spricht gegen gemeinsame Faktoren; zu viel kann Redundanz bedeuten. |
| Bartlett-Test      | Prüft, ob die Korrelationsmatrix von einer Einheitsmatrix abweicht. | Signifikanz spricht dafür, dass Faktorenanalyse grundsätzlich sinnvoll sein kann.         |
| KMO-Kriterium      | Bewertet, ob die Variablen für Faktorenanalyse geeignet sind.       | Niedrige Einzelwerte weisen auf problematische Items hin.                                 |
| Kaiser-Kriterium   | Zählt Faktoren mit Eigenwert größer 1.                              | Nützlich, aber mechanisch und oft zu grob.                                                |
| Parallelanalyse    | Vergleicht echte Eigenwerte mit Zufallsdaten.                       | Stärkere Entscheidungshilfe, aber keine automatische Wahrheit.                            |

|                |                                                 |                                                             |
|----------------|-------------------------------------------------|-------------------------------------------------------------|
| Faktorladungen | Zeigen, welche Items auf welche Faktoren laden. | Faktoren müssen klar, stabil und inhaltlich benennbar sein. |
|----------------|-------------------------------------------------|-------------------------------------------------------------|

Take-Away: **Statistische Verfahren ersetzen keine Theorie.** Wenn ein Faktor statistisch entsteht, aber inhaltlich nicht plausibel benennbar ist, sollte er nicht unkritisch verwendet werden. Umgekehrt kann eine theoretisch erwartete Struktur empirisch nicht ausreichend gestützt sein.

### Cronbachs Alpha richtig lesen

Cronbachs Alpha misst interne Konsistenz. Werte um 0,70 gelten oft als akzeptabel, 0,80 als gut und 0,90 als sehr gut. Sehr hohe Werte können aber auch bedeuten, dass Items fast dasselbe fragen. Alpha prüft nicht automatisch Eindimensionalität und nicht automatisch Validität. Deshalb sollte Alpha zusammen mit Faktorenanalyse und Iteminhalt interpretiert werden.

**Beispielhafte Konsequenz:** Wenn ein Indikator viele unplausible oder inkonsistente Werte enthält, kann er trotz theoretischer Relevanz aus der Analyse fallen. Das ist methodisch sauberer, als eine scheinbar nützliche, aber nicht vertrauenswürdige Variable beizubehalten.

## 10. Regression: Interpretieren statt nur berechnen

Regressionsmodelle wurden in der LV verwendet, um bspw. Zusammenhänge zwischen konstruierten Faktoren, Unternehmensmerkmalen und Innovationsmaßen zu untersuchen. Die zentrale Interpretationsregel lautet: Ein Koeffizient beschreibt einen geschätzten Zusammenhang unter Kontrolle der übrigen Modellvariablen. Daraus folgt noch keine Kausalität.

### Modellgüte und Koeffizienten

- $R^2$  beschreibt den Anteil erklärter Varianz, aber nicht automatisch, ob das Modell sinnvoll, kausal oder für Vorhersagen geeignet ist. Adjusted  $R^2$  ist besonders nützlich beim Vergleich von Modellen mit unterschiedlich vielen Prädiktoren, weil es Modellkomplexität berücksichtigt.
- Koeffizienten hängen von der Einheit der Variablen ab. Standardisierte Variablen erleichtern den Vergleich von Effektstärken.
- Konfidenzintervalle zeigen Unsicherheit besser als ein einzelner Punktwert. Breite Intervalle deuten auf unpräzise Schätzungen hin.
- p-Werte beantworten nur eine enge Testfrage. Sie ersetzen keine Beurteilung von Effektgröße, Datenqualität und Modellannahmen.

### Diagnostik: Was kann schiefgehen?

| Diagnosebereich       | Worum es geht                                             | Praktische Reaktion                                                                |
|-----------------------|-----------------------------------------------------------|------------------------------------------------------------------------------------|
| Residuenverteilung    | Sind Fehler ungefähr symmetrisch und ohne extreme Ränder? | Histogramme, Q-Q-Plots und Kennzahlen gemeinsam betrachten.                        |
| Heteroskedastizität   | Ändert sich die Varianz der Residuen systematisch?        | Residualplots prüfen; ggf. robuste Standardfehler verwenden.                       |
| Autokorrelation       | Sind Fehler voneinander abhängig?                         | Vor allem bei Zeitreihen oder geordneten Daten relevant.                           |
| Einflussreiche Punkte | Verändern einzelne Beobachtungen das Modell stark?        | Cook's Distance, Leverage und studentized Residuals gemeinsam prüfen.              |
| Multikollinearität    | Sind Prädiktoren durch andere Prädiktoren erklärbar?      | VIF, Condition Number, Variablendefinition und theoretische Überschneidung prüfen. |

### Einflussreiche Beobachtungen

**Studentized Residuals** zeigen starke Abweichungen im Y-Wert. **Leverage** zeigt ungewöhnliche Positionen im X-Raum. **Cook's Distance** verbindet beides und fragt, wie stark ein Punkt die Koeffizienten beeinflusst. Auffällige Werte sollten untersucht, aber nicht automatisch gelöscht werden. Besonders sinnvoll ist eine Kombination aus Diagnosekennzahlen, Plot und fachlicher Plausibilität.



## Multikollinearität

Multikollinearität macht Koeffizienten nicht systematisch falsch, aber instabil. Standardfehler steigen, Vorzeichen können kippen, und kleine Datenänderungen können große Modelländerungen bewirken. Ein hoher VIF (*variance inflation factor*) kann auch entstehen, wenn eine Variable nicht mit einer einzelnen, sondern mit einer Kombination anderer Variablen stark zusammenhängt.

Wie beim AirQuality-Beispiel in der LV gesehen, sind Regressionskoeffizienten nicht einfach als isolierte Wirkung einer Variable zu verstehen. Sie zeigen immer einen **partiellen Zusammenhang**: Was trägt diese Variable zur Erklärung bei, **wenn die anderen Variablen im Modell konstant gehalten werden**? Sobald mehrere Prädiktoren ähnliche Information enthalten, etwa verschiedene Luftschadstoff- oder Sensormesswerte, wird diese Interpretation schwieriger. Die Koeffizienten beschreiben dann nicht mehr den einfachen Zusammenhang zwischen einer Variable und der Zielvariable, sondern **den Beitrag jenes Anteils, der nicht bereits durch andere Variablen erklärt wird**.

Multikollinearität kann deshalb dazu führen, dass Koeffizienten instabil werden: Sie können stark größer oder kleiner werden, wenn eine andere Variable entfernt wird, und sogar das Vorzeichen wechseln. Das bedeutet nicht automatisch, dass sich der reale Zusammenhang umgedreht hat. Häufiger zeigt es, dass mehrere Variablen gemeinsame Varianz teilen und das Modell diese gemeinsame Information je nach Spezifikation unterschiedlich auf die Prädiktoren verteilt. Wird eine starke Variable entfernt, übernehmen andere Variablen teilweise ihre Rolle im Modell. Dadurch verändert sich ihre geschätzte Bedeutung.

Für die Anwendung heißt das: **Koeffizienten, Standardbetas und p-Werte sollten immer im Kontext des gesamten Modells interpretiert werden**. Besonders bei inhaltlich ähnlichen oder technisch verwandten Variablen ist Vorsicht geboten. Eine Variable mit kleinem Koeffizienten ist nicht zwingend unwichtig; sie kann durch andere Variablen überdeckt sein. Umgekehrt ist ein großer Koeffizient nicht automatisch ein stabiler Haupteffekt. Wichtig ist daher, Modellvarianten zu vergleichen, Korrelationen und Multikollinearität zu prüfen und Koeffizienten nicht als endgültige Rangliste kausaler Einflussgrößen zu lesen.

## Common Method Bias

Beim **Common Method Bias** geht es darum, dass alle Variablen aus demselben Messinstrument stammen und daher eine gemeinsame Antworttendenz enthalten können. Ein zusätzlicher *CommonFactor* kann als Diagnose dienen: Steigt  $R^2$  stark oder ändern sich Koeffizienten deutlich, ist Vorsicht geboten.

## 11. Praktischer Arbeitsablauf für eigene Fragebogen-Analysen

Die folgende Checkliste fasst den reflexiven Arbeitsmodus zusammen.

1. Fragestellung klären: Welche Variable soll erklärt, beschrieben oder vorhergesagt werden?
2. Datenstruktur prüfen: Spalten, Datentypen, Wertebereiche, Sondercodes, offensichtliche Inkonsistenzen.
3. Fehlende Werte analysieren: Wie viel fehlt, wo fehlt es, und warum könnte es fehlen?
4. Plausibilität visualisieren: Histogramme, Scatterplots, Korrelationen und einfache Gruppenauswertungen.
5. Bereinigungsentscheidungen dokumentieren: Was wurde geändert, entfernt, umkodiert oder imputiert?
6. Konstrukte prüfen: Passen Items theoretisch zusammen und zeigen sie empirisch ausreichende Kohärenz?
7. Modelle vergleichen: Nicht nur  $R^2$ , sondern Koeffizienten, Unsicherheit, Diagnostik und Stichprobe vergleichen.
8. Sensitivität testen: Ändern sich Aussagen bei anderer Imputation, anderen Grenzwerten oder anderen Modellspezifikationen?
9. Ergebnisse vorsichtig formulieren: Zusammenhang, Unsicherheit und Grenzen klar benennen.