

DATA CLEANING & DATA ANALYTICS

Daten & Datenbereinigung

AGENDA



Was sind Daten?

Wissenstreppe nach North, Kategorien von Daten



Warum Datenbereinigung?

Datenlebenszyklus, Beispiele




Dirty Data – Clean Data?

Dirty Data, 5 C's of Data


WAS SIND DATEN?

Wissenstreppe nach North,
Kategorien von Daten

BRAINSTORMING: WAS SIND DATEN?



WAS SIND DATEN?



ÜBUNG: VOM ZEICHEN ZU WISSEN



Einzelarbeit.



Finden Sie ein Beispiel aus aus Ihrem Arbeits-/Studiumsalltag und geben Sie die ersten vier Stufen „Zeichen-Daten-Information-Wissen“ explizit an.




Posten Sie Ihr Beispiel im Chat.




10 Minuten

Wissenstreppe 4.0 (North & Maier)




KATEGORISIERUNG VON DATEN

vorhanden
konstant



Digitalisierung

analog, digital




Strukturierungsgrad

strukturiert, semi-
strukturiert,
unstrukturiert




Qualität

qualitativ, quantitativ



Format

metrische Daten, Text-,
Bild-, Audio-,
Videodaten



Rechenoperationen

nominal-, ordinal-,
interval-,
verhältnisskaliert



Verwendungszweck

Meta-, Stamm-, Transaktions-,
Referenz-, organisationsweite
Struktur-, Transaktions-
struktur-, Inventardaten

Daten konvertiert } mehrere
multimodal } Formate

WARUM DATENBEREINIGUNG?

Datenlebenszyklus, Beispiele

WARUM DATENBEREINIGUNG?



„Garbage in, garbage out“
Qualität bestimmt Verwendbarkeit




Praxisfaustregel: 60–80% Projektzeit für
Datenvorbereitung



Folgen schlechter Qualität: verzerrte Analysen,
fehlerhafte Modelle, Compliance-Risiken

WIE KOMMT ES ZU DIRTY DATA?

„Stille Post“



BEISPIEL: RAUMFAHRT-NAVIGATION

NASA: Mars Climate Orbiter (1999)



Datenproblem

Einheitenmix: Schubdaten in Pfundsekunden (lbf·s) wurden als Newtonsekunden (N·s) interpretiert.

Folge in der Analyse

falsche Bahnkorrekturen; die Sonde verglühte in der Marsatmosphäre.

Auswirkungen

- Verlust der Mission im Wert von 125 Millionen Dollar
- Schaden für die Glaubwürdigkeit der NASA
- Hervorhebung der Bedeutung von Datenkonsistenz und -standardisierung.

BEISPIEL: GESUNDHEITSSEKTOR

Public Health/COVID-19-Dashboards (2020-2022)



Abbildung: pixabay

Datenprobleme

- in Großbritannien wurden aufgrund eines veralteten Datenformats Fälle nicht aufgenommen;
- in anderen Ländern gab es Backlogs und Batch-Korrekturen an Feiertagen, uneinheitliche Test-/Fall-Definitionen zwischen Behörden, Nachmeldungen ohne korrekte Onset-Datierung.

Folge in der Analyse

Schein-Peaks und scheinbare Trendbrüche; falsche Trendinterpretation durch Meldeverzug bzw. Datenverlust;

Auswirkungen: Fehlentscheidungen bei Maßnahmen, wenn auf Rohmeldedatum aggregiert; infizierte Menschen gaben das Virus weiter

BEISPIEL: NLP-AUFGABEN

Textauswertungen



Abbildung: pixabay

Texte (z. B. aus Social Media) werden in Hinblick auf Sentiment und Topics untersucht.

Problem


aggressive Bereinigung (Entfernen von Emojis, „nicht/kein“ als Stoppwörter, falsche Unicode-Normalisierung) entfernt semantisch wichtige Signale; Mehrsprachigkeit/Code-Switching unmarkiert.

Folge in der Analyse

- Systematische Fehlklassifikation (z. B. positives Emoji entfernt → neutral/negativ)
- irreführende Topic-Kohärenzen;
- starke Performance-Einbrüche auf kurzen Texten (Reviews, Social Posts)

DIRTY DATA – CLEAN DATA?

Dirty Data, 5 C's of Data



TYPEN VON „DIRTY“ DATA

Duplicate Data

doppelte Daten
(identische Kunden,
Rechnungen etc.)

Insecure Data

unsichere Daten
(Zugriffskontrollen,
Verschlüsselung)

Outdated Data

veraltete Daten
(alte Adressen, alte
Messungen)

Incomplete Data

unvollständige Daten
(fehlende Adressen,
Labels)

Inaccurate Data

ungenauere Daten
(manuelle Schätz-
werte, unklare
Einheitenpräzision)

Inconsistent Data


inkonsistente Daten
(Datums-/ Zahlen-
formate, untersch.
Einheiten)

Hoarded Data

Datenhortung
(Just-in-Case-
Sammlungen)

Incorrect Data

fehlerhafte Daten
(Tippfehler,
vertauschte Werte)



5 C's OF DATA QUALITY

Clean²

- keine Missing Values
- keine ungenauen Werte
- nicht außerhalb des Range
- keine Typos ...
- alternativ: Correct

Consistent¹

- Bedeutung der Daten („Wahrheit“)
- Repräsentation der Daten (Bezeichnung)

Conformed¹

- festgelegte Grenzen
- klare Einheiten
- Beispiel: Studierende

Current¹

- Was bedeutet „aktuell“?
- Datenvolumen bei Echtzeit?
(Beispiel: Aktienkurse in Echtzeit und Schlusskurs)

Complete²

- Breite und Tiefe der Daten
- Beispiel: Namen von Kund*innen
- alternativ: Comprehensive

1 Kimball & Caserta 2004
2 DAMA International 2017

praxisübliches Merkschema, basierend auf Grundsätzen des Data-Warehouses bzw. Master-Data-Managements (in den Begriffen variierend)

ETHISCHE DATENNUTZUNG

Nur weil wir etwas mit Daten machen können, sollen wir es auch tun?

