

BEREINIGUNG VON TEXTDATEN

Linguistische Grundlagen (Teil 1)

AGENDA



Sprache & Sprachproduktion

Aufgaben, Teilbereiche, empirische Forschung & Statistik



Sprache als Datenobjekt?

Korpus, Dokument, Satz, Wort

TEXTBEISPIEL

Auszug aus einem Korpus (Korpus: Customer-Feedback-DE-2026, fiktiv)

[2026-02-12 17:24:09 UTC] (id: tw-4471) @maxi_kunde: Bestellt am Mo., Paket noch IMMER nich da... wtf?!? 🤔 📦 Tracking-Link tot (& 404). Hotline sagt: "bald" 😬 Pls fix!!! Hab extra EXPRESS gebucht!!! #Service?? #fail #MÃ¼nchen Order: #ORD-9Z31, Ref: 12-345-AB Screens: <https://bit.ly/3xyz> @ShopSupport

SPRACHE & SPRACHPRODUKTION

Arten von (menschlichen)
Sprachen, Parole vs
Performance

u

v

w

x

y

z



... points
... and unseen
fingers curled in

r

s

palm forward

verbal vs nonverbal
↓ ↓
gesprochen nicht-gesprochen

Weitergabe von
Information

Regelwerk für
Kommunikation zw. Menschen
(oder mehr?)


↓
Mensch - Maschinen

Was ist
Sprache?

↓
System mit
Zeichen + Regeln

↓
Selbstgespräch? ↗ Intention?

(LINGUISTISCHE) EINTEILUNG



MENSCHLICHE SPRACHE

Strukturalismus: Ferdinand de Saussure (1847-1913)

langue: abstraktes System aus Zeichen, Regeln und Oppositionen innerhalb einer Sprachgemeinschaft

parole: konkrete, situative Sprachverwendung einzelner Sprachverwender*innen

generative Transformationsgrammatik: Noam Chomsky (geb. 1928)

(Erzeugungsgrammatik mit Transformationsregeln), 1957 (und später)

Kompetenz: Fähigkeit, grammatikalische Ausdrücke zu erzeugen & zu verstehen (internalisiertes Regelsystem)

Performanz: tatsächlicher Gebrauch unter Beschränkungen wie Gedächtnislast, Fehlern, Ablenkungen

BEISPIEL

Textdaten: Langue? Parole? Kompetenz? Performanz?

[2026-02-12 17:24:09 UTC] (id: tw-4471) @maxi_kunde: Bestellt am Mo., Paket noch IMMER nich da... wtf?!? 🙄📦 Tracking-Link tot (& 404). Hotline sagt: "bald" 🙄 Pls fix!!! Hab extra EXPRESS gebucht!!! #Service?? #fail #MÃ¼nchen Order: #ORD-9Z31, Ref: 12-345-AB Screens: <https://bit.ly/3xyz> @ShopSupport

SPRACHPRODUKTION

Medium: mündlich (phonisch) vs.
schriftlich (graphisch)
im Sinne von Nähe vs. Distanz

Modus/Konzeption

(konzeptionelle Ausprägung):
Realisierung als gesprochene
oder geschriebene Sprache

Kommunikationsbedingungen:

- Dialog
- Vertrautheit der Partner
- *face-to face*-Interaktion
- freie Themenentwicklung
- keine Öffentlichkeit
- Spontaneität
- ‚involvement‘
- Situationsverschränkung
- Expressivität
- Affektivität


Sprache
der
Nähe

*Versprachlichungs-
strategien:*

- Prozeßhaftigkeit
- Vorläufigkeit
- geringere:
- Informationsdichte
- Kompaktheit
- Integration
- Komplexität
- Elaboriertheit
- Planung

- Monolog
- Fremdheit der Partner
- raumzeitliche Trennung
- Themenfixierung
- Öffentlichkeit
- Reflektiertheit
- ‚detachment‘
- Situationsentbindung
- ‚Objektivität‘

Sprache
der
Distanz



BEISPIEL: MEDIUM/MODUS

Medium? Modus?

[2026-02-12 17:24:09 UTC] (id: tw-4471) @maxi_kunde: Bestellt am Mo., Paket noch IMMER nich da... wtf?!? 🙄📦 Tracking-Link tot (& 404). Hotline sagt: "bald" 🙄 Pls fix!!! Hab extra EXPRESS gebucht!!! #Service?? #fail #MÃ¼nchen Order: #ORD-9Z31, Ref: 12-345-AB Screens: <https://bit.ly/3xyz> @ShopSupport

SPRACHE ALS DATENOBJEKT

Korpus, Dokument, Satz, Wort

SPRACHE ALS DATENOBJEKT

Datenebenen: Korpus, Text, Satz, Wort, Zeichen

Kontextabhängigkeit: Domäne, Genre, Medium (z. B. Social Media vs. Berichte)

Text

kohärente Einheit sprachlicher Zeichen durch Textualitätskriterien
zusammengehalten

Korpus

systematisch zusammengestellte, maschinenlesbare Sammlung von Texten mit
Metadaten (Zeit, Quelle, Sprache/Varietät, evtl. Annotationen)

kuratierte Korpora für Analysen: Sampling-Strategien, Balancing (z. B. pro
Plattform/Monat), klare Inclusion/Exclusion-Kriterien und dokumentierte
Datenherkunft

TEXTUALITÄTSKRITERIEN

(Beaugrande/Dressler 1981)

Textkohäsion

formaler Zusammenhalt eines (geschriebenen oder gesprochenen) Textes; durch äußerliche Markierungen gekennzeichnet wie Tempusformen, Pronomen, Deiktika

Textkohärenz

Zusammenhang zwischen aufeinanderfolgenden Sätzen oder Sprachakten

Intentionalität: Fähigkeit, sich auf etwas zu beziehen


Akzeptabilität: Grad der Angemessenheit und Verständlichkeit eines Ausdrucks

Informativität: neue Information

Situationalität: Kontext; alle Faktoren wie Zeit, Ort, Umstände

Intertextualität: kein Text ist ohne Bezug zu anderen Texten denkbar

ZERLEGUNG EINES KORPUS



DOKUMENTEBENE: PARATEXT & METADATEN

Datenverarbeitung: Dokument = technische Einheit mit Paratexten und Metadaten

Paratext

Rahmen-Textelemente wie Titel, Untertitel, Abstract etc.; strukturieren das Lesehandeln und signalisieren Diskursfunktion

Metadaten

maschinenlesbare Beschreibungen, die Korpusaufbau, Sampling, Bereinigung steuern

wie Autor*in, Zeitstempel, Quelle/Plattform, Sprache/Varietät, Genre/Register-spezifikation, Rechte/Consent, Version/Revision

ermöglichen Filtern der Dokumente nach bestimmten Eigenschaften

DOKUMENTEBENE: STRUKTUR

Makrostruktur

- Abschnitte (Paragrafen) = Sinnblöcke
- Sektionen mit Überschriften = Segmentation von Themen
- Tabellen & Formeln = Repräsentation spezialisierter Objekte
- Zitate = Kodierung von Intertextualität
- Hyperlinks, Hashtags, Mentions & IDS = deiktische Hinweise & relationale Marker

Kohäsionsebene

sprachliche Mittel wie Anapher/Katapher, Substitution, Ellipsen, Konnektoren, Lexikalschemata

BEISPIEL

mögliches Korpus? Dokumente des Korpus?

[2026-02-12 17:24:09 UTC] (id: tw-4471) @maxi_kunde: Bestellt am Mo., Paket noch IMMER nich da... wtf?!? 🙄📦 Tracking-Link tot (& 404). Hotline sagt: "bald" 🙄 Pls fix!!! Hab extra EXPRESS gebucht!!! #Service?? #fail #München Order: #ORD-9Z31, Ref: 12-345-AB Screens: <https://bit.ly/3xyz> @ShopSupport

SATZEBENE: SATZTYPEN & STRUKTUR

Satz = grammatisch/intonatorisch abgeschlossene Einheit mit mind. einem finiten Verb, repräsentiert eine illokutive Kraft (Aussage, Frage, Aufforderung)

Satztypen

Hauptsatz (Matrixsatz), Nebensatz (Subordination), Teilsatz

Deklarativsatz (Aussage), Interrogativsatz (Frage), Imperativsatz (Aufforderung), Exklamationsatz (Ausruf), Ellipse (syntaktisch reduzierte pragmatisch vollständige Ausdrücke)

syntaktische Struktur

mehrere syntaktische Konstituenten (= Gruppe von Wörtern, die eine gemeinsame grammatische Funktion erfüllen)

Subjekt, Prädikat, Objekt, Adverbiale (Zusatzinformation zu Zeit, Ort etc.)

SATZEBENE: UNTERSCHIEDUNG

orthographischer Satz

durch Punkt, Fragezeichen oder Ausrufzeichen begrenzt

syntaktischer Satz

durch Grammatik bestimmt

spontane schriftliche Kommunikation (wie Chat, Social Media)

Unterscheidung nicht einfach

Grund: Mehrfachzeichen „?!?“, fehlende Groß-/Kleinschreibung, Emojis

BEISPIEL

Wie viele Sätze? Welche Satztypen? Ellipsen? Syntax erkennbar?

Metadaten

①

[2026-02-12 17:24:09 UTC] (id: tw-4471) | @maxi_kunde | Bestellt am Mo., Paket noch
IMMER nicht da... wtf?!? 🤔📦 Tracking-Link tot (& 404) | Hotline sagt: "bald" 🤔 | Pls
fix!!! Hab extra EXPRESS gebucht!!! #Service?? #fail #München Order: #ORD-9Z31,
Ref: 12-345-AB Screens: <https://bit.ly/3xyz> @ShopSupport

WORTEBENE: LEXEM & WORTFORM

Lexem

abstrakte Grundform eines Wortes im mentalen Lexikon einer Sprache

Wortform

konkrete orthographische Realisierung eines Lexems im Kontext

entstehen durch Flexion (= grammatische Veränderung eines Wortes, ohne die Bedeutung zu verändern)

im Deutschen: Kasus (Fall), Numerus (Singular/Plural), Genus (grammatisches Geschlecht), Tempus (Zeitform), Person

Lexem: laufen

Wortformen: laufe, läufst, lief, gelaufen

WORTEBENE: WORTARTEN

Einteilung nach grammatischen Eigenschaften

- **Substantive** (Nomen): Hochschule, Gedanke, Skriptum
- **Verben**: laufen, lernen, denken
- **Adjektive**: groß, schnell, weit
- **Adverbien**: heute, dort, sehr
- **Pronomen**: Personal- (ich, du, es), Possessiv- (mein, dein), Demonstrativ- (diese, jener), Relativpronomen (der, die, das)
- **Präpositionen**: in, auf, mit, wegen
- **Konjunktionen**: und, oder, weil, dass

WORTEBENE: KOMPOSITUM

zusammengesetztes Wort, das aus mehreren Bestandteilen besteht

- **Grundwort:** bestimmt Wortart, Genus & grammatische Eigenschaften
- **Bestimmungswort:** nähere Erläuterung des Grundwortes
- **Fugenelement:** zwischen den Bestandteilen eines Kompositums

z.B. Haustür

Grundwort = Tür, Bestimmungswort = Haus

z.B. Arbeitsamt

Grundwort = Amt, Bestimmungswort = Arbeit, Fugen-s

QUELLEN

Saussure, Ferdinand de 1916, *Cours de linguistique generale, publie par Charles Bally et Albert Sechehaye avec la collaboration de Albert Riedlinger*. Paris: Payot.

Koch, P., Oesterreicher, W. (1985). Schriftlichkeit und kommunikative Distanz. Zeitschrift für Germanistische Linguistik 35(3).

BEISPIELTEXT 1: SOCIAL-MEDIA-THREAD

POST_ID=SMX_2011

user=@run_fast

time=2026-03-02T18:41

Heute wollte ich eigentlich **laufen**. Also ich laufe sonst oft... früher lief ich jeden Tag; gestern bin ich sogar gelaufen – aber heute? nope.

5km geplant... 2km geschafft 🏃

Die neue **Fitness-Tracking-App-Einstellung** zeigt komische Werte:

pace="7:90/km" ???

<post> Ich dachte erst mein ****Sportuhren-Synchronisationsproblem**** wäre schuld, aber vielleicht lag es einfach daran dass ich zu spät gestartet habe weil: Kaffee, Regen, Motivation = 0 </post>

jemand Tipps? training tips welcome pls.

Kommentare

@anna_run:

Did you warm up?? warm-up ist wichtig. Ich laufe, lief und werde laufen egal ob Regen.

@run_fast:

true... hab ich wohl vergessen :-/

BEISPIELTEXT 2: SOCIAL-MEDIA-DISKUSSION

POST_ID: SMX_2042

platform: microblog

Hab heute ein neues **Kaffeevollautomat-Reinigungsprogramm** ausprobiert... Ergebnis? naja.

Der Kaffee schmeckt besser glaube ich zumindest... vielleicht.

Aber der **Milchschaumtemperatur-Regelungs-Sensor** spinnt 🤪

Hab die Anleitung gelesen (engl. version btw) und da steht:

“Press CLEAN for 5 sec then restart device.”

gemacht... hat nix gebracht.

jemand Erfahrung mit sowas??? oder ist mein Gerät einfach kaput??

BEISPIELTEXT 3: REKLAMATION

TICKET=SUPPORT_44012

product=NoiseCanceling-Headphones-Pro-Edition

Sehr geehrtes Team,

ich schreibe wegen eines **Bluetooth-Verbindungsabbruchproblems**. Das Gerät verbindet sich zwar... aber dann trennt es die Verbindung wieder.

Ich habe getestet:

verbinden

verbunden

Verbindung verloren

Also: verbinden → verbunden → getrennt.

Gestern funktionierte es noch; heute funktioniert es nicht mehr. Früher funktionierte alles.

Firmware v1.3.2 laut App.

<device-log> error: reconnect_failed error: timeout </device-log>

pls help asap.

BEISPIELTEXT 4: UNTERNEHMENSANTWORT

CASE_ID=SUPPORT_44012

Sehr geehrte Kundin,

thank you for contacting our **Customer-Experience-Support-Service-Team**.

Ihr beschriebenes **Bluetooth-Verbindungsabbruchsproblem** könnte durch eine fehlerhafte Firmware entstehen.

Bitte versuchen Sie folgende Schritte:

Gerät **resetten**

Firmware **updaten**

Gerät erneut **verbinden**

Markdown Anleitung:

1. press reset
2. hold button 10 sec
3. restart device

Falls das Problem weiterhin besteht melden Sie sich bitte erneut.

Best regards / Mit freundlichen Grüßen

Support Team

BEISPIELTEXT 5: ERFAHRUNGSBERICHT

TRIP_ID=EU_7782

city=Budapest

Ich reise gern... ich reiste früher öfter... dieses Jahr bin ich wieder gereist. Budapest war mein Ziel.

Die **Parlamentsgebäude-Besuchergruppen-Organisation** war allerdings chaotisch.

Ticket kaufen → warten → nochmal warten → Führung.

guide sagte ständig: “please stay together”. Einige Leute blieben zusammen andere nicht.

Food war gut tho:

Paprikagulasch

Langos

irgendein **Straßenküchen-Imbissstand-Spezialgericht**

Hotelbewertung:

room: ok

wifi: unstable

noise-level: high

würde ich wieder reisen? wahrscheinlich ja.

BEISPIELTEXT 6: ERFAHRUNGSBERICHT

TRAVEL_ID=EU_7789

destination=Amsterdam

Amsterdam ist interessant... sehr interessant sogar.

Ich gehe gern zu Fuß. Ich ging viel. Gestern bin ich 18km gegangen laut Schrittzähler-App-Analyse.

Die **Grachteboot-Touristenmassen-Managementstrategie** der Stadt scheint nicht zu funktionieren lol.

Ein Tourist fragte mich:

“Excuse me where is the Anne Frank house??”

Ich sagte: idk sorry.

Hostel war ok aber das **Zimmerreinigungs-Zeitplan-Koordinationssystem** funktionierte nicht wirklich.

BEISPIELTEXT 7: TECHNIKFORUM

THREAD_ID=PCHELP_88912

Problem: Laptop startet nicht richtig.

Symptome:

boot → freeze

restart → freeze again

safe-mode → manchmal ok

Gerät: Dell XPS-Laptop-Mainboard-Temperaturüberwachungs-System evtl defekt?

Ich starte den PC → er startet → er startete gestern auch noch → heute startet er nicht.

<system-log> boot_error=0x44AF memory_check=failed </system-log>

jemand ideas?? maybe BIOS update??

BEISPIELTEXT 8: KLEINANZEIGE

AD_ID=MARKET_2026_002

Verkaufe mein **City-Tour-Pendler-Alltagsfahrrad** 🚲

Specs:

Marke: Cube

Model: TravelPro-Urban-Edition

Zustand: gut aber **Gangschaltungs-Justierungsproblem**

Beschreibung:

Das Fahrrad fährt gut... es fuhr immer gut... gestern bin ich damit gefahren und alles war ok.

Nur manchmal springt der Gang raus; vermutlich ein **Schaltwerks-Feineinstellungs-Problem**.

Kontakt:

email: seller@mail.test

phone: 0660-445-99xx

Preis: 250€ VB.

BEISPIELTEXTE 9: TEXTBEREINIGUNG

„Also... gestern haben wir mal wieder das ganze Kundenfeedback durchgeklickt – OMG, so viel Stuff! 🤪 Manche Posts waren mega kurz, nur Emojis 🧠💡, andere mit Dialekt: ‚I hob des net b'stellt!‘ Und dann Ironie ohne Ende („toller“ Service...). Nebenbei: ein paar Daten doppelt, manches uralt. Wir haben dann erstmal normalisiert, Tokenisierung drüber, PII raus – und zack, Themen klarer, Sentiment weniger sprunghaft. Aber mal ehrlich: Ohne Dialekt-Mapping und Emoji-Kategorien bleibt's messy. Nächstes Sprintziel: bessere Stopplisten & Decompounding für Komposita. Let's go! 🚀“