

BEREINIGUNG VON TEXTDATEN

Linguistische Grundlagen (Teil 2)

AGENDA

- Vom Text zum Token
Tokenisierung
- Vom Laut zum Zeichen
Begriffsklärung
- Zeichen & Zeichenmodelle
de Saussure, Peirce

VOM TEXT ZUM TOKEN

Tokenisierung



TOKENISIERUNG

Textanalyse = Untersuchung von konkreten Instanzen eines sprachlichen Elements in einem Text

Tokenisierung = Zerlegung eines Textes in kleinere Einheiten wie Wörter, Zeichen oder Subwörter

Ziel: Sprachen lesbar und verarbeitbar zu machen

klassische und regelbasierte Methode

basieren auf einfachen Regeln; Probleme bei domänenspezifischen Symbolen, komplexen Sprachen; Wort-Tokenisierung, Regex-Muster

statistische und Subwort-Methoden

Token anhand von Mustern in großen Textdaten; Verringerung der Anzahl an unbekannten Wörtern

FRAGEN ZU TOKENISIERUNG

Was ist eine Einheit?

Ein Satz? Ein Wort? Ein Zeichen?

Ist eine Silbe eine eigene Einheit und können mehrere Wörter eine Einheit ergeben?

Beispiel: *hm* versus *New York*

Welche Grenzen ergeben sich?

Wie können die Grenzen festgelegt werden?

TYPE VERSUS TOKEN

(Wort-)Typ

- jede eindeutige Form, unabhängig von Wiederholung
- bestimmtes Wort im Vokabular
- für Vokabulargrößen, Wortstatistiken, TF-IDF-Berechnungen

(Wort-)Token

- jede Instanz eines Worttyps in einem Text
- Wiederholungen werden berücksichtigt
- Tokens können unterschiedliche Formen haben
- Textverarbeitung, Zählen von Wörtern, n-Gramm-Modelle

BEISPIEL

Text:

Ich zerlege den Text und ich zerlege den Satz.

Worttypen:

ich – zerlege – den – Text – und – Satz

Worttoken:

Ich – zerlege – den – Text – und – ich – zerlege – den – Satz

FORMEN VON TOKENS

unterschiedliche Formen, abhängig vom Analyseziel

Token kann

- Wort
- Wortteil
- einzelne Zeichen oder
- Satzzeichen

sein

Grundlage für Bag-of-Words-Modelle, Topic-Modeling, Sentimentanalyse

EBENEN DER TOKENISIERUNG

Satz-Tokenisierung (z. B. bei Diskursanalyse)

- Token = Satz

Wort-Tokenisierung (z. B. NLP-Aufgaben)

- Token = Wort;
- anhand von Leer- oder Satzzeichen
- schwierig bei seltenen oder neuen Wörtern

Zeichen-Tokenisierung

- Zeichen = Token
- kann zu langen Sequenzen führen

Subwort-Tokenisierung (z. B. Transformer-Modelle)

- Wortsegment = Token

ARTEN VON TOKENISIERUNG

Stemming = Wörter auf ihre Wortstämme (= Stem) reduzieren, über einfache Regeln wie Entfernen von Suffixen

- Overstemming: zu starke Reduktion von Wörtern; Verzerrung des Wortes ; (verschiedene Wörter mit selbem Wortstamm) oder Wortsegmente ohne Bedeutung
- Understemming: semantisch zusammenhängende Wörter werden nicht zum selben Wortstamm reduziert

Lemmatisierung = Wörter auf ihre Grundform (= Lemma) reduzieren, unter Berücksichtigung von Wortart und Kontext

BEISPIEL

Text: „*Ich zerlege den Text.*“

Tokens: „Ich“, „zerlege“, „den“, „Text

Stemming: „ich“, „zerleg“, „den“, „text“

Lemmatisierung: „ich“, „zerlegen“, „der“, „Text“

Text: „*Der Politiker spricht über Politik.*“

Tokens: „Der“, „Politiker“, „spricht“, „über“, „Politik“

Stemming: „der“, „politik“, „sprich“, „über“, „politik“ (Overstemming)

Lemmatisierung: „der“, „Politiker“, „sprechen“, „über“, „Politik“

Stemming

Wörter auf Wortstamm (= Stem) reduzieren, über einfache Regeln wie Entfernen von Suffixen
lernen, lernt, lernte → *lern*

Overstemming

„zu viel“ gekürzt

Politiker, Politik → *politik*

Understemming

„zu wenig“ gekürzt

sprechen, spricht → *sprech, sprich*

Lemmatisierung

Wörter auf Grundform (= Lemma) reduzieren, unter Berücksichtigung von Wortart und Kontext
lernen, lernt, lernte → *lernen*

Politiker, Politik → *Politiker, Politik*

sprechen, spricht → *sprechen*


ÜBUNG

*Text: Die Datenanalysen zeigen, dass die Wissenschaftler*innen regelmäßig Daten analysieren.*

Aufgabe:


1. Tokenisieren Sie den Text (jedes Wort, Satzzeichen → Token).
2. Führen Sie ein Stemming und eine Lemmatisierung der Tokens durch.
3. Diskutieren Sie die Unterschiede.

LINGUISTISCHE EBENEN



VOM LAUT ZUM ZEICHEN

Begriffsklärung



Phonetik/ Phonologie

„lautliche“ Ebene
der Sprache

Untersuchung von
Lauten im Sprachsystem

Lautschrift: Umsetzung
der Laute in Buchstaben
(IPA-Lautschrift)

Graphetik/ Graphematik

„schriftliche“ Ebene
der Sprache

Untersuchung der
Schreibung und ihrer
Regeln

Phonem-Graphem-
Beziehung

Morphologie

Untersuchung der
Struktur von Wörtern
und deren Bestandteile

Wortstamm &
Wortformen

PHONOLOGIE: PHON & PHONEM

Phon: kleinste tatsächlich hörbare und messbare Einheit der mündlichen Sprache (Sprachlaut)

Phonem: kleinste **bedeutungsunterscheidende** lautliche Einheit einer Sprache (mentale bzw. systemische Einheit bzw. funktionale Lautkategorie)

z. B. *laufen* vs *raufen* (/r/ und /l/ sind Phoneme im Dt.)

Allophon: unterschiedliche Realisierungen eines Phonems

z. B. [r] und [R] im Deutschen

Verwendung von Lautschrift (International Phonetic Association, IPA)

BEDEUTUNG FÜR DATENANALYSE

- Orthografie: Phonem-Graphem-Beziehung (dazu später)
- automatische Spracherkennung bzw. Sprachsynthese:
mündliche Signale werden in kleinere Einheiten zerlegt, die phonetischen oder phonemischen Kategorien entsprechen; diese Kategorien werden für die Identifikation von Wörtern genutzt.
- Analyse von Dialekten, Akzenten & Sprachvariation (Phone)

ENTSTEHUNG VON SCHRIFTSYSTEMEN

Autonomiehypothese

Schrift = autonomes Zeichensystem
z. B. Sprachentwicklung

Dependenzhypothese

Schrift = sekundäres Zeichensystem, das der Notation von Lauten dient
z. B. Großschreibung, Akronyme

Interdependenzhypothese

gegenseitige Abhängigkeit bzw. Autonomie beider Sprachformen und
synchrone Dominanz der mündlichen Sprachform

GRAPHEMATIK: SCHRIFTSYSTEME

Bildzeichen (Piktogramme): erste Formen einer Schrift
z. B. frühe ägyptische Hieroglyphen, Anfänge des Chinesischen

logografisches Schriftsystem: Logogramme = Repräsentation eines Wortes ohne Bezug zur Lautgestalt

phonograpisches System: Schriftzeichen hängen mit Lauten zusammen (phonologisches Prinzip)

- **Silbenschrift:** Zeichen für ganze Silben (z. B. Sumerisch, Chinesisch)
- **Alphabetschrift:** Zeichen für einzelne Laute

GRAPHEMATIK: GRAPH & GRAPHEM

Graph: konkrete grafische Realisierung (= visuelle Form) eines Schriftzeichens (Buchstabe)

Graphem: kleinste **bedeutungsunterscheidende** Einheit im Schriftsystem einer Sprache (Bedeutung durch Unterschiede in der Schrift)

z. B. *Rad* vs *Rat*

Deutsch: <a> <c> <d> <e> <f> <g> <h> <i> <j> <k> <l> <m> <n> <o> <p>
<r> <s> <t> <u> <v> <w> <x> <y> <z> <ä> <ö> <ü> <ß> <qu> <ch> <sch>

Mehrgraph: Grapheme, die aus mehreren Graphen bestehen
<qu> , <ch> , <sch>

GRAPHEMATIK: PHONEM - GRAPHEM

Alphabetsprache: Beziehung zwischen Graphemen und Lauten
(**Phonem-Graphem-Beziehung**)

nicht eindeutig: Graphem kann mehrere Laute repräsentieren bzw. ein Laut kann durch verschiedene Grapheme dargestellt werden

z. B.

Graphem <v> → Phoneme /f/, /w/

Phonem /f/ → Grapheme <f>, <v>

BEDEUTUNG BEI DATENANALYSE

- Optical Character Recognition (OCR) (= automatische Texterkennung aus Bildern oder gescannten Dokumenten)
- Datenanalyse bei Zusammenführung von Texten aus verschiedenen Quellen (Schriftarten, Zeichenvarianten)
- digitale Textverarbeitung: Einlesen von Texten als Folge von Schriftzeichen (Unicode-Kodierung)
- Datenanalyse: Normalisierung von Graphemen (unterschiedliche Schreibweisen, diakritische Zeichen wie é, è, e)

MORPHOLOGIE: MORPH & MORPHEM

Morph: konkrete Realisierung eines Morphems in einem Wort (oder Äußerung); tatsächlich auftretende Form in einem bestimmten Kontext (*parole*)

Morphem: kleinste sprachliche Einheit, die eine **Bedeutung** oder **grammatische** Funktion trägt (*langue*)
aus Klassifizierung von Morphen

Allomorph: verschiedene Formen desselben Morphems

z. B. Pluralendungen *Pfeil-e*, *Bote-n*, *Mensch-en*, *Auto-s*
oder 2. Person Singular wie *gib-st*, *hatt-est*

MORPHOLOGIE: MORPHEM

Unterscheidung nach „frei“/“gebunden“ und „lexikalisch“/“grammatisch“

- **freie Morpheme:** entsprechen nicht weiter zerlegbaren Wörtern wie *gut, Haus, Schiff, und, oder*
- **gebundene Morpheme:** Kombination von verschiedenen Morphen z. B. Affixe (für Flexion oder Ableitungen von Wortstämmen) wie *Hund-e, arbeit-en, ver-kaufen*

Morphem	frei	gebunden
lexikalisch	<i>Kind, grün, gern, lauf</i>	<i>-chen, un-, -heit</i>
grammatisch	<i>und, damit, zu</i>	<i>-en, -st, ge-</i>

MORPHOLOGISCHE SEGMENTIERUNG

(Zerlegung eines Wortes in Morphe)

1. Die Segmentierung muss vollständig sein; es darf kein Rest übrig bleiben.
2. Die Zerlegung muss der Zerlegung in Bedeutungsanteile entsprechen.
3. Die Segmente müssen in gleicher (oder wenigstens ähnlicher) Bedeutung auch in anderen Zusammensetzungen vorkommen.

BEDEUTUNG BEI DATENANALYSE

- Gruppierungen von Wortvarianten (Morph)
- grammatische Muster erkennen (über Allomorphe und Morphe)
- Natural Language Processing (NLP)

Analyse der Struktur einer Sprache: Wörter bestehen aus mehreren Morphemen, die gemeinsam eine komplexe Bedeutung erzeugen

Analyse von Texten, z. B. beim Preprocessing wie Zurückführen auf Wortstamm/Grundform

ÜBERSICHT

Begriff	Ebene	Definition		Beispiel	Relevanz für Datenanalyse
Phon	Laut	konkrete Lautrealisierung	konkret	[ʁ], [tʰ]	indirekt (phonetische Normalisierung, ASR/OCR-Fehler)
Phonem	Laut	kleinste bedeutungstragende Lauteinheit	abstrakt	/r/ /t/	mittel (phonetische Hashes, Name-Matching)
Graph	Schrift	kleinste Schrifteinheit		r, ʀ, ɾ	mittel/hoch (OCR –Fehler, Normalisierung)
Graphem	Schrift	kleinste bedeutungsdifferenzierende Einheit	abstrakt	/r/, /l/	hoch (Unicode, Normalisierung, Segmentierung)
Morph		konkrete Form eines Morphems im Text	konkret	-en, ver-	hoch (Affix-Erkennung, Dekompoundierung)
Morphem		kleinste bedeutungstragende Einheit	abstrakt		hoch (Lemmatisierung, Feature-Normalisierung)

ÜBUNG

Wörter: Rat, Rad, Bett, Beet, Katze, Tatze, Schule, Unfreundlichkeit

Aufgabe:

1. Identifizieren Sie **Minimalpaare** und markieren Sie das **Phonem**, das den Bedeutungsunterschied erzeugt.
2. Markieren Sie für die gleichen Wörter die **konkreten Laute (Phone)**, die unterschiedlich realisiert werden können.
3. Zerlegen Sie die Wörter in konkrete Morphe und markieren Sie die **Morpheme**.
4. Markieren Sie die **Grapheme** und die unterschiedlichen **Graphen**, falls sichtbar (z. B. a, ä, ß).

ZEICHEN & ZEICHENMODELLE

de Saussure, Peirce



SEMIOTIK

Wissenschaft von **Zeichen** und **Zeichensystemen**

Untersuchung,

- wie Zeichen Bedeutung erzeugen,
- welche Zeichenarten es gibt und
- wie diese miteinander verknüpft werden

Fragen für Gebrauch von Zeichen wie

- Welche Einheiten werden als Zeichen wahrgenommen?
- Wie werden Bedeutungen kodiert und dekodiert?
- Welche Rolle spielen kulturelle Konventionen?

WAS IST EIN ZEICHEN? (1/2)

(1) etwas Sichtbares, Hörbares, das als Hinweis dient, etwas deutlich macht, mit dem jmd. auf etwas aufmerksam gemacht oder zu etwas veranlasst wird:

- Der Hornist gab das Zeichen zum Aufbruch
- Er gab ihr mit der Taschenlampe ein Zeichen
- Die Kinder verständigten sich über Zeichen miteinander
- Als Zeichen ihrer Versöhnung umarmten sie sich

(2) Kenntlichmachung von etwas, dem Hinweis auf etwas, dienende Kennzeichnung, Markierung oder als solcher

- ein kreisförmiges Zeichen
- Mach' Dir lieber ein Zeichen auf die betreffende Seite.
- Sie kerbte ein Zeichen in die Baumrinde

WAS IST EIN ZEICHEN? (2/2)

(3) festgelegte, mit einer bestimmten Bedeutung verknüpfte undeine ganz bestimmte Information vermittelnde (graphische) Einheit:

- mathematische, chemische etc. Zeichen, Noten (Musik)
- Sprache als System von Zeichen

(4) etwas Sichtbares, Hörbares, Spürbares, was jmdm. etwas [an]zeigt, Anzeichen, Symptom, Vorzeichen:

- Das ist kein gutes Zeichen.
- Seine hohe Temperatur war ein klares Zeichen für Fieber.
- Das Baby gab Zeichen des Unmutes von sich.

ZEICHEN

Unterteilung oft in Form & Bedeutung

- **sprachliche Zeichen**: Wörter, Morphem, Graphem
- **nichtsprachliche Zeichen**: Symbole, Gesten, Bilder, Emojis, Verkehrsschilder

Datenanalyse: digitale Kommunikation besteht aus verschiedenen „Zeichen“

Linguistik: Zeichen = Brücke zwischen konkreten Realisierungen & abstrakten Einheiten

Antike

Zeichen als Abbild
der Realität oder als
Werkzeug der
Kommunikation

17.-18. Jh.

Sprachphilosophie
Zeichen als
Willensäußerung und
Symbol

19. Jh./20. Jh.

Pragmatismus

Zeichen als triadische Relation
zwischen Zeichen, Objekt und
Interpretant; Unterscheidung
Ikon, Index, Symbol

21. Jh.

Digital Semiotics
Anwendung auf NLP,
OCR, Unicode, Emojis,
Social Media

Mittelalter

Semiologie in Logik,
Zeichen als Zeichen
der Zeichen (z. B. Gott
als Urzeichen)

19. Jh.

Strukturalismus:
Zeichen als Einheit aus
Signifiant und Signifikat,
Arbitrarität der Zeichen

20. Jh.

Semiotic Schools
Pragmatismus,
Strukturalismus,
Poststrukturalismus,
multimodale Semiotik

DE SAUSSURE: DYADISCHES ZEICHEN

Ferdinand de Saussure (1857-1913)

- Begründer der modernen Linguistik & Semiotik
- sprachliches Zeichen = grundlegende Einheit der Sprache
 - Signifikant/signifiant (Ausdruck)
 - Signifikat/signifié (Inhalt)
- zufällige Beziehung zwischen Signifikant & Signifikat (soziale Konvention)
- keine Information zu „Zweck“ des Zeichens

DE SAUSSURE: DYADISCHES ZEICHEN


Signifikat (signifié)

- Bedeutung (mentales Konzept), das der Form zugrundeliegt
- z. B. : Konzept einer Rose (Vorstellung)

Signifikant (signifiant)

- Form des Zeichens, das wahrnehmbare Element
- Laut, Schriftzeichen, Folge von Buchstaben
- z.B. „Rose“

untrennbar verbunden (wie „Vorder- und Rückseite eines Blattes“)



BEISPIELE

Zeichen	Signifikant	Signifikat	
Baum			
Haus			
			

PEIRCE: TRIADISCHES ZEICHEN

Charles Saunders Peirce (1893-1914)

- Entwicklung einer triadischen Zeichentheorie
- Bedeutung liegt nicht nur in Form
- Kontext & Interpretation in Zeichentheorie integriert

PEIRCE: TRIADISCHES ZEICHEN

Repräsentamen (Zeichen)


Form des Zeichens (ähnlich dem signifiant)

Objekt

das, worauf sich das Objekt bezieht (reales Ding, Konzept, Ereignis)

Interpretant (Idee)

Bedeutung oder mentaler Effekt beim Rezipienten, was das Zeichen für jemanden bedeutet



TYPEN VON ZEICHEN NACH PEIRCE

Typ	Definition	Beispiel
Icon	Ähnlichkeitsbeziehung zum Objekt	Piktogramm, Emoji, Diagramm
Index	verbunden mit indiziertem Objekt; direkte kausale oder physische Verbindung	Rauch → Feuer Zeigefinger → Richtung
Symbol	beliebiges Zeichen; konventionell, Bedeutung muss gelernt werden	Verkehrszeichen, Wörter wie Baum

Datenanalyse: relevant für multimodale Zeichen wie Bilder, Emojis, Icons, Indizes in Texten, die maschinell erkannt & interpretiert werden müssen



de Saussure

- Graphem/Graph → Signifikat
- Morphem/Morph → Teile des Signifikats im Wortkontext
- Anwendung: Tokenisierung, OCR-Normalisierung, Textklassifikation

Peirce

- multimodale Daten: Emojis, Symbole, Indizes in Texten
- Tokens können nicht nur Wörter, sondern auch Icons, Satzzeichen, Emojis oder Zeichenketten darstellen

ÜBUNG

Beispieltext :



Achtung: Feuer im Labor! Das Wort „Warnung“ ist deutlich zu lesen.

Aufgabe:

1. Identifizieren Sie alle **Zeichen** im Text (Wörter, Emojis, Satzzeichen).
2. Bestimmen Sie den **Signifikanten (Form)** und das **Signifikat (Bedeutung)** nach Saussure.
3. Klassifizieren Sie die Zeichen nach Peirce: **Ikon, Index, Symbol**.
4. Diskutieren Sie, welche Zeichen in **NLP/Textanalyse** als Tokens verwendet werden könnten.

QUELLEN

Jurafsky, D., Martin, J. H. (2026). *Speech and Language Processing*.
<https://web.stanford.edu/~jurafsky/slp3/>

Müller, H. M. (2009). *Arbeitsbuch Linguistik. Eine Einführung in die Sprachwissenschaft*. UTB.

Pittner, K. (2025). *Einführung in die germanistische Linguistik*. UTB